


Проактивний моніторинг інфраструктури

Запобігання піковим навантаженням за допомогою машинного навчання.



Проблема: Реактивний підхід



Традиційний моніторинг лише констатує факт аварії. Коли навантаження CPU/RAM сягає 100%, ви вже боретеся з наслідками.


Потреба: Проактивний підхід



Вирішення: Надання інтервального прогнозу на 15 хвилин у майбутнє, що перетворює гасіння пожеж на планове керування ресурсами.

ANATOMY OF A PREDICTION

Історичні дані



[Lag features,
Rolling mean,
Time of day]




Легковагова неймерережа

Легковагова
неймерережа

MLP / TensorFlow Lite



Інтервальний прогноз



T-0 T+15 min

Горизонт

Точний прогноз на 15 хвилин
вперед.

Пік

Визначення максимального
використання ресурсу
(CPU/RAM).


Межі

Нижня та верхня межа
(наприклад, 10-90% квантилі),
що формують коридор
ймовірних значень.

Контроль у реальному часі: Переклад ML на мову дій


Web-дашборд автоматично візуалізує стан усіх вузлів (Nodes) та завчасно сповіщає операторів про ймовірні аномалії.

Статус-індикатор:
Миттєва оцінка ризику
(SAFE, WARNING, CRITICAL).





Headroom: Точний запас доступного ресурсу до 100% потужності.

Quality metrics: Контроль точності моделі (MAE та коефіцієнт покриття).




Прогнозний графік:
Затінена зона майбутнього коридору через WebSocket (WSS) у реальному часі.

ПОРІВНЯННЯ ПІДХОДІВ: ТРАДИЦІЙНІ СИСТЕМИ ТА НАШЕ ML-РІШЕННЯ

ПАРАМЕТР	Традиційні системи	→ Наше ML-рішення
Час до сповіщення (Time-to-alert)	0 хв (пост-фактум)	15 хв (завчасне) ✓
Тип аналітики (Analysis type)	Точкова статистика	Інтервальний прогноз (коридор) 
Споживання ресурсів (Resource usage)	Високе (важкі агенти)	Ультра-низьке (TFLite оптимізація) 
Зберігання даних (Data storage)	Зовнішні дорогі БД	Ізольована локальна SQLite 

Можливі переваги ПЗ: **Висока точність**, **автономність** та **миттєва інтеграція** з існуючим Prometheus без оверхеду.

Архітектура без зайвого навантаження




Вимоги до апаратних ресурсів: Ефективність замість витрат

Production (Go-застосунок + Inference)

CPU: 1-2 ядра (x86-64 / ARM64)

RAM: від 512 МБ (Ультра-легка модель TensorFlow Lite)



Disk: 100-500 МБ (Локальна SQLite)

GPU: Не вимагається (\$0 витрат на відеокарти)

Навчання моделі (Python Pipeline)

CPU: 2-4 ядра

RAM: від 4 ГБ

Оточення: Python 3.9+, Docker

Вартість впровадження мінімальна завдяки відсутності потреби у важких обчислювальних кластерах.

Впровадження та підготовка кадрів: Нульовий поріг входу



Оператори та Адміністратори

Вимоги: Жодних знань машинного навчання.

Дія: Система перекладає складні прогнози на прості статуси дій (SAFE, WARNING, CRITICAL).
Управління через інтуїтивний веб-дашборд.



Data/ML Інженери

Вимоги: Стандартний стек (Python).

Дія: Автоматизований пайплайн перенавчання (pipeline.py).
Система автоматично генерує та підхоплює оновлені .tflite артефакти.



Швидкий старт: Розгортання з вихідного коду (Go 1.21+) або через Docker Compose за лічені хвилини. Мінімальний час до отримання першої цінності (Time-to-Value).